

AI: Kunstmatige Intelligentie


Week 3: Taalmodellen en Toepassingen

Jan Martin Jansen

Neurale Netwerken

Netwerk van verbonden Neuronen

- input laag: codering van probleem
- output laag: codering van oplossing





Leren door **verbindingen** tussen neuronen **sterker** of **zwakker** te maken

- vergelijk gegenereerde output met gewenste output
- stel gewichten bij zodat het antwoord dichterbij gewenste antwoord komt gebruikmakend van backpropagation
- herhaal dit met voldoende voorbeelden
- de **structuur** van het neurale netwerk bepaalt voor welk **toepassingsgebied** het geschikt is (manier waarop lagen met elkaar verbonden zijn)

Neurale Netwerken

- zeer succesvol voor beeldherkenning en spraaktoepassingen (genereren en herkennen)



Neurale Netwerken

Het succesverhaal voor moderne AI


- (bijna) ieder AI systeem wordt ermee gemaakt
- gewichten worden uitsluitend bepaald door training
- idee al heel oud, maar je hebt zeer krachtige computers nodig
- je moet wel in staat zijn je probleem te coderen in termen van input en gewenste output en de afwijking kunnen bepalen
- hoe doe je dit bv met **taal**?

Grote Taal Modellen (Large Language Models, LLM)

Nieuwe **revolutie** in Neurale Netwerken

Trainen van modellen met natuurlijke taal dmv teksten

Gebruik van zgn **Transformer Modellen**



- maken het mogelijk **verbanden** te ontdekken tussen **verschillende delen** uit een **tekst**
 - 'hij ging op de **bank zitten**'
 - 'hij zette zijn **geld** op de **bank**'
- opvolgende lagen kijken naar steeds grotere verbanden in teksten
- kunnen daardoor woorden, zinnen en ook grotere structuren in hun **context** zien
- dit kan tot (honderd)duizenden woorden!

Transformer Model


Artikel

‘Attention Is All You Need’


Ashish Vaswani, Noam Shazeer, Niki Parmar, e.a
Google Brain, 2017

Eigenschappen:

- **attentie** mechanisme: ontdekt verbanden tussen verschillende delen van tekst
- **parallele** verwerking!
- heel goed te optimaliseren (met GPU's, etc)
- techniek gepubliceerd en **niet** geheim!



LLM: training



LLM's worden getraind op enorme hoeveelheden data:

- internet pagina's, documenten, boeken, wetenschappelijk artikelen, etc
- tot **petabytes** aan data (10^{15} B)

Trainen concreet:

- invoer: **korte combinaties** van **letters** (lettergrepen, korte woorden, woordenboek van 50.000 items)
- woord gerepresenteerd door getallenreeks (**vector**) van 12.000 getallen
- model heeft **geen a priori** kennis van **taal**!
- leert taal door training (zoals een kind taal leert: alleen met voorbeelden)

LLM: training (vervolg)

Basisidee: model leert **voorspellen** wat **volgende** woord in tekst zal zijn

- **gewichten** worden **bijgesteld** zodat het resultaat steeds beter wordt
- gebeurt wel in **context** grotere tekst
- niet alleen binnen een zin, maar ook in grotere gehelen:
 - 'Marie is **jarig** vandaag. Wim kwam binnen en gaf haar een'
 - 'Wim is **smoor** op Marie. Hij kwam de kamer in en gaf haar een'
- diepere lagen in het model kijken naar steeds grotere verbanden
 - eerste lagen naar losse woorden
 - iets diepere lagen naar zinnen
 - nog diepere lagen naar paragrafen, bladzijden
 - nog dieper naar duizenden woorden, hele boeken
- op deze manier ontstaat een representatie van '**betekenis**' van taal
 - posities in de 12.000 dimensionale vectorruimte coderen taalconcepten

LLM

Training gebeurt dmv een vorm van backpropagation

- labels zijn de correcte volgende woorden
- er worden honderden miljarden parameters getraind
- modellen zijn totaal **honderden tot duizenden gigabytes** groot

LLM modellen slaan verder niets op!

- er is dus **geen** database met de oorspronkelijk informatie
- model wordt **volledig** bepaald door **waarden** van **gewichten**
- model slaat dus geen feitelijke informatie op!
- op **feitelijk vragen** kan het antwoord dus **fout** zijn!



LLM

Voordeel LLM trainen

- kan **parallel**
 - grote stukken tekst (100 - 1000 woorden) worden in één keer verwerkt
- itt oude modellen die strikt sequentieel getraind moesten worden

Trainen LLM

- gebruik van zeer grote serverparken met TPU's en GPU's
 - berekeningen zijn niet ingewikkeld, maar wel heel **veel**
 - TPU en GPU kunnen veel berekeningen tegelijk doen (matrixbewerkingen bv)
- trainen kan **weken** tot **maanden** duren
- trainen enkel model kost tot **honderden miljoenen** dollars!
- maar gaat volledig geautomatiseerd (geen menskracht)!

Initieel Model

Na basistraining Initieel Model: nv GTP3, GTP4 of GTP5


- is een pure tekst-voorspeller
- geen notie van stijl, veel ruis, inconsistent, hallucinerend
- kan wel vertalen, samenvatten, maar met bovengenoemde bezwaren
- geen 'persoonlijkheid'

Dus niet nuttig voor echt gebruik

Finetunen

Fine Tunen: aanpassen voor specifiek gebruik

- dit gebeurt wel mbv **mensen**:
 - kiezen beste antwoord uit reeks voorbeelden
- leidt tot verdere **aanpassing gewichten**
- duurt minder lang en kost veel minder (computertijd) dan training grote model



Voorbeelden

- medische, juridische of financiële toepassingen
- geschikt maken voor **programmeren, wiskunde** en **redeneren**
- dialoog met gebruiker: **chatGPT** is **gefinetunede** versie van GPT!
 - **chatGPT** genereert **woord voor woord** een antwoord met alle al gegenereerde tekst steeds als input

Initieel Model en Finetunen

Samenvatting: Trainen in 2 stappen:

Stap 1

- automatisch verwerken grote hoeveelheden tekst
 - bijstellen gewichten gebaseerd op correct voorspellen volgende woord
 - gebruik van **Transformer** model om verbanden in teksten te ontdekken
 - woorden zijn gerepresenteerd door punten in 12.000 dimensionale ruimte
 - model bestaat uit honderden lagen en miljarden neuronen

Stap 2

- finetunen model voor specifieke taak, mbv menselijke input
 - bijstellen gewichten
 - dwing het model op een bepaalde manier te 'denken'
 - geef feedback op gegenereerde antwoorden (bv keuze uit meerdere)

Hallucineren: probleem van Taalmodellen

LLM


- statistische modellen
- voorspellen van meest waarschijnlijke volgende woord
- of wat er staat **waar** is???
- het genereert gewoon een goedlopende tekst
- gevolg: model hallucineert (vooral in eerdere versies, bv chatGPT 3)

Oplossing

- eerst informatie opzoeken op internet
- deze info toevoegen aan de oorspronkelijke vraag!
- voorkomt tevens dat model steeds met nieuwe informatie geupdate moet worden

Hallucineren

RAG **RETRIEVAL AUGMENTED GENERATION**



Voorkomen Hallucineren

Prompt Engineering

- gebruikers instrueren om duidelijke en specifieke vragen te stellen
- model vragen bronnen te citeren

Menselijke feedback

- modellen trainen met menselijke feedback (**Reinforcement Learning from Human Feedback (RLHF)**)
- menselijke beoordelaars corrigeren onjuiste antwoorden en belonen correcte antwoorden
- model leert zo correcte antwoorden te geven


Zelfreflectie

- model krijgt opdracht eigen antwoord te evalueren en corrigeren

Multimodale Modellen

Nieuwste versies van Gemini, GPT, etc, zijn **MultiModaal**

- **combineren** een **taalmodel** met **beeld**, **video** en **spraak**
- model ontdekt zelf hoe beeld, spraak en tekst bij elkaar horen



Redeneren in AI

Klassieke Taalmodellen

- goed in chat-achtige toepassingen
- minder goed in **logische** en **wiskundige** taken (**redeneren**)
- in taal hoeft je immers niet altijd heel precies te zijn

Door slimme fine-tuning kan je de modellen wel geschikt maken voor redeneren

- dwing af dat model tussenstappen laat zien
- welke tussenstappen waren nodig om tot antwoord te komen?
- **beloon** goede redeneringen en **bestraf** slechte (Reinforcement Learning)
- zo leert het systeem goede redeneringen te maken




LLM en Taal

LLMs leren de ‘**betekenis**’ van taal uit alleen tekst

Heeft de kijk op taal veranderd:

- je hebt geen **grammatica's** of andere taaltheorie nodig om taal te leren/bestuderen itt wat bv **Chomsky** dacht
- taal is meer dan alleen maar communicatiemiddel, je kan er op fundamentele manier kennis in uit drukken
- bevestiging ideeën **Wittgenstein** over taal: **betekenis** van taal is af te leiden uit de **context** waarin het gebruikt wordt zonder expliciet te refereren naar de werkelijkheid
- vb: in model verhoudt man zich tot vrouw als koning tot koningin (als punten in de ruimte)



OpenAI en (chat)GPT Generative Pre-Trained Transformer

OpenAI: opgericht in **2015**

Doel: “het bevorderen en ontwikkelen van **vriendschappelijke** AI, op een manier die de **mensheid** als geheel **ten goede** komt”


Versies GPT:

- GPT (2018): 117 miljoen parameters, toonde de potentie van **Transformer** model aan
- GPT-2: (2019) 1.5 miljard parameters, presenteerde boven verwachting
 - bijna menselijk aandoende tekstgeneratie
 - coherente teksten
 - logische redenering en andere taken waar het model niet specifiek op was getraind
- GPT-3: (2022) 175 miljard parameters, complete verrassing
 - schaalvergroting leidt tot magische (emergente) resultaten, begrijpen context voorbij directe tekstverwerking
 - code genereren, wiskundige problemen oplossen, lange coherente teksten genereren
- GPT-4 (2023): 1 biljoen parameters (geschat), verdere verfijningen
 - langere en complexere contexten, beter taalbegrip (nuances en ambivalentie)
 - beter geschikt voor specifieke doelen (medisch, juridisch, etc)
 - genereren creatieve teksten
 - multi-modaal: tekst, beeld en geluid

OpenAI

openAI o1 (2024)

- systeem dat logisch kan redeneren
- goede scores op programmeerproblemen en wiskunde
- niveau PhD student voor scheikunde, natuurkunde, biologie
- ook gebaseerd op **LLM** en **Transformer**
- getraind om problemen stap voor stap op te lossen
- geeft uitleg over de genomen stappen



■ NIEUWS

OpenAI claimt doorbraak met model dat kan 'redeneren'

OpenAI

GPT-5 en chatGPT-5

- waarschijnlijk niet echt groter dan GPT-4
- minder hallucinaties
- bepaald automatisch of vraag 'redeneren' vereist
- meerdere versies: ook kleine modellen voor standalone gebruik
- langere contexten: beter draad van dialoog volgen

Alternatief gebruik Transformer Modellen

Weersvoorspelling [Nooit meer een onverwachte bui? Hoe AI helpt het weer beter te voorspellen | de Volkskrant](#)

Hoe gaat het nu?

- zeer complexe **meteorologische** modellen van atmosfeer, etc
- draait op zeer krachtige computers (de grootste die er zijn)
- input: heel veel metingen, temperatuur, luchtdruk, windrichting, etc

Met Transformer:

- train model met sequenties van weer over langere perioden, waarbij weer van volgende dag voorspeld moet worden
- totaal **geen** meteorologische kennis nodig!
- trainen is duur, maar voorspellen kost veel minder computerkracht
- GraphCast van Google voorspelt in 90% al beter dan krachtigste model in Europa
 - getraind met 39 jaar aan data
 - voorspelt weer binnen minuut

Casestudy: Google DeepMind

DeepMind opgericht 2010, eigendom Google vanaf 2014

Ontwikkelde baanbrekende AI producten

Doel

- oplossen fundamentele problemen intelligentie mbv machine learning
- begonnen met spelletjes zoals **Atari** games
- later ook **schaken** en **Go**

Hardware

- gebruik van speciaal gemaakte Tensor Processor Units (**TPU**)



AlphaGo

Go werd beschouwd als één van de ultieme uitdagingen voor AI

- 10^{170} bord posities
- de beste Go programma's voor 2010 speelde op niveau amateur
 - in 1997 werd de wereldkampioen schaken al verslagen!
 - technieken schaken werken niet voor Go
- **AlphaGo** is gebaseerd op diepe **neurale** netwerken
 - trainen op bestaande **menselijke** partijen en
 - **simuleren** van partijen gebruikmakend van **Reinforcement Learning**
 - versloeg in 2015 **Lee Sedol** (top Go speler)
 - documentaire: <https://www.youtube.com/watch?v=WXuK6gekU1Y>
- Belangrijke **milestone** in geschiedenis AI!

AlphaZero



Uitgebracht in 2017 en opvolger AlphaGo

- ook geschikt voor andere spelletjes zoals **schaken**, **shogi**
- uitsluitend leren door **zelfspel** (dus **niet** op bestaande partijen)
- spelregels enige input!
- beduidend sneller dan AlphaGo met slechts iets betere hardware
 - versloeg AlphaGo met groot gemak
- versloeg alle bestaande schaakprogramma's (waaronder wereldkampioen **Stockfish**) na slecht 4 uur trainen van model
- de schaakwereld was stomverbaasd:
 - 'alsof een buitenaardse beschaving op aarde was geland en ons kwam uitleggen wat schaken is'
 - Gary Kasparov: 'menselijke en intuïtieve manier van schaken ipv brute force aanpak' van DeepBlue

Reinforcement Learning

AlphaGo en AlphaZero maken gebruik van **Reinforcement** Learning


Leren van optimaal gedrag door **trial and error**, beloningen of straffen. Er is sprake van directe interactie met een omgeving. Iedere actie wordt beloond of bestraft (soms pas op later moment).

Eigenschappen

- evenwicht zoeken tussen gebruikmaken van kennis (**exploitatie**) en nieuwe dingen proberen (**exploratie**)

Toegepast in:

- spelletjes
- robotica
- autonome voertuigen



Nobelprijs Natuurkunde 2024 voor grondleggers AI!



Geoffrey Hinton

Belangrijke grondlegger van AI

- neurale netwerken en **backpropagation** (jaren 80)
- beeld- en spraak-herkenning (jaren 90 en later)
- deep learning revolutie (jaren 10 en later)
- **Turing award** 2018, **Nobelprijs** 2024

Belangrijke uitspraken:

- 'LLM's zijn **echt intelligent** en creatief'
- '**AI** zal ons in intelligentie **voorbijstreven** in 5 - 20 jaar'
- 'AI zou de wereld kunnen **overnemen** en we moeten dus heel **voorzichtig** zijn'
- 'Als je AI vraagt om een oplossing te bedenken voor het klimaatprobleem kan het beslissen dat het uitroeien van de mensheid de beste manier is om dat te doen'
- 'Als je Elon Musk en Mark Zuckerberg vertrouwt om de toekomst te bepalen, moet je wel dom zijn. Daar mag je me op citeren'

Geoffrey Hinton: gevaren AI

- snelle ontwikkeling AI en potentiële gevaren
- mogelijkheid superintelligentie die mensheid overtreft
- overtuiging grote taalmodellen echt intelligent zijn
- AI is in staat tot **redeneren** (itt andere critici)
- noodzaak effectieve **regelgeving** om ontwikkeling en gebruik AI te controleren
- potentiële risico's beperken

Meer citaten:

- 'Grote taalmodellen hebben een beter algoritme om te leren dan wat wij door evolutie ontwikkeld hebben. Dat is beangstigend'
- 'Eens we systemen hebben die even slim zijn als wij gaan we snel systemen hebben die slimmer zijn. We zitten daar al vrij dicht bij'

Nobelprijs Scheikunde 2024 voor AlphaFold



NOBELPRISET I KEMI 2024
THE NOBEL PRIZE IN CHEMISTRY 2024



KUNGL.
VETENSKAPS-
AKADEMIEN
THE ROYAL SWEDISH ACADEMY OF SCIENCES



Photo: University of Washington

David Baker
University of Washington
USA

"för datorbaserad proteindesign"
"for computational protein design"



Photo: The Royal Society

Demis Hassabis
Google DeepMind
United Kingdom

"för proteinstrukturprediktion"
"for protein structure prediction"




Photo: BWA Foundation

John M. Jumper
Google DeepMind
United Kingdom

AlphaFold

Eiwitten zijn opgebouwd uit **aminozuren**

- er bestaan **22** verschillende aminozuren
- hiermee kunnen oneindig veel verschillende eiwitten opgebouwd worden
 - vergelijk met woorden opgebouwd uit letters
- volgorde van aminozuren bepaalt **3D** structuur van eiwit
 - eiwitten **vouwen** zich tot complexe **structuren** afhankelijk van **positie** aminozuren
 - Nobelprijs 1972
- **3D** structuur bepaalt **werking** van eiwit
 - wat doet het in het lichaam: hormoon, weefsel, enzym, etc
- moeilijk structuur van eiwit te bepalen vanuit volgorde
 - 'prediction problem'
 - tweejaarlijkse competitie: voorspellen structuur vanuit volgorde vanaf 1994
 - **heilige graal** van **biologie**



AlphaFold

Voorspellen structuur eiwit


- tot 2016 in maximaal 40% van de gevallen
- 2018 AlphaFold1: 60% van de gevallen
- 2020 AlphaFold2: 90% van de gevallen
- 2024 AlphaFold3: nog nauwkeuriger

Wat kan het nog meer?

- nieuwe **biomaterialen** ontwerpen
- meer inzicht in **ontwikkeling** (erfelijke) **ziektes**
- met AlphaFold3 kan ook de **interactie** van **eiwitten** voorspeld worden
 - **werking** van medicijnen **voorspellen**
 - nieuwe **medicijnen** **ontwerpen**
- voorspellen hoe je met DNA eiwitten kunt bouwen

STRUCTURE SOLVER

DeepMind's AlphaFold 2 algorithm significantly outperformed other teams at the CASP14 protein-folding contest — and its previous version's performance at the last CASP.



AlphaFold

Hoe werkt het?

- probleem benaderen als **patroonherkenningsprobleem** (zoals legpuzzels)
- transformer netwerk getraind met honderdduizenden bekende eiwitten
- gebruikmakend van **supervised** en **unsupervised** training
- met **reinforcement** learning

Voor wie?

- database met eiwitstructuren staan beschikbaar voor wetenschappers

Andere Producten van DeepMind

Gemini / chatGPT: goed in converseren, onbetrouwbaar voor (wiskunde) problemen

AlphaProof concurrent van **openAI o1**

- combineert neurale netwerken **AlphaZero** met symbolische AI in **Lean**
 - wiskundige formalisme voor computers
- kan echt **logisch** redeneren
- zilveren medaille op **Internationale Wiskunde Olympiade 2024**
 - zelfs opgave die maar door 5 van 609 deelnemers kon worden gemaakt
 - maar makkelijkere opgaven juist weer niet!
- wel zelfstandig problemen oplossen
- (nog) niet nieuwe wiskunde bedenken
- veelbelovende ontwikkeling

