


AI: Kunstmatige Intelligentie

Week 4: Toekomst en Bedenkingen
Jan Martin Jansen

Taalmodellen (LLM): herhaling

De nieuwe revolutie in AI

- gebaseerd op neurale netwerken
- gebruik van Transformer model met Attentie mechanisme
 - ontdekt relaties tussen woorden, zinnen, delen van teksten
 - model vangt op emergente wijze de betekenis van taal
- trainen gebaseerd op **volgende** woord voorspellen
 - volledig automatisch door (heel erg veel) teksten door het systeem te halen (heel kostbaar!)
 - tegenwoordig ook: beeld, video en audio via omzetting
- finetunen
 - geschikt maken voor specifieke doelen: chat dialoog, redeneren
 - hier menselijke input



Nobelprijs Scheikunde 2024 voor AlphaFold



NOBELPRISET I KEMI 2024
THE NOBEL PRIZE IN CHEMISTRY 2024



KUNGL.
VETENSKAPS-
AKADEMIEN
THE ROYAL SWEDISH ACADEMY OF SCIENCES



Photo: University of Washington

David Baker
University of Washington
USA

"för datorbaserad proteindesign"
"for computational protein design"



Photo: The Royal Society

Demis Hassabis
Google DeepMind
United Kingdom

"för proteinstrukturprediktion"
"for protein structure prediction"




Photo: BWA Foundation

John M. Jumper
Google DeepMind
United Kingdom

AlphaFold

Eiwitten zijn opgebouwd uit **aminozuren**

- er bestaan **22** verschillende aminozuren
- hiermee kunnen oneindig veel verschillende eiwitten opgebouwd worden
 - vergelijk met woorden opgebouwd uit letters
- volgorde van aminozuren bepaalt **3D** structuur van eiwit
 - eiwitten **vouwen** zich tot complexe **structuren** afhankelijk van **positie** aminozuren
 - Nobelprijs 1972
- **3D** structuur bepaalt **werking** van eiwit
 - wat doet het in het lichaam: hormoon, weefsel, enzym, etc
- moeilijk structuur van eiwit te bepalen vanuit volgorde
 - 'prediction problem'
 - tweejaarlijkse competitie: voorspellen structuur vanuit volgorde vanaf 1994
 - **heilige graal** van **biologie**



AlphaFold

Voorspellen structuur eiwit


- tot 2016 in maximaal 40% van de gevallen
- 2018 AlphaFold1: 60% van de gevallen
- 2020 AlphaFold2: 90% van de gevallen
- 2024 AlphaFold3: nog nauwkeuriger

Wat kan het nog meer?

- nieuwe **biomaterialen** ontwerpen
- meer inzicht in **ontwikkeling** (erfelijke) **ziektes**
- met AlphaFold3 kan ook de **interactie** van **eiwitten** voorspeld worden
 - **werking** van medicijnen **voorspellen**
 - nieuwe **medicijnen ontwerpen**
- voorspellen hoe je met DNA eiwitten kunt bouwen

STRUCTURE SOLVER

DeepMind's AlphaFold 2 algorithm significantly outperformed other teams at the CASP14 protein-folding contest — and its previous version's performance at the last CASP.



AlphaFold

Hoe werkt het?

- probleem benaderen als **patroonherkenningsprobleem** (zoals legpuzzels)
- transformer netwerk getraind met honderdduizenden bekende eiwitten
- gebruikmakend van **supervised** en **unsupervised** training
- met **reinforcement** learning

Voor wie?


- database met eiwitstructuren staan beschikbaar voor wetenschappers

Andere Producten van DeepMind

Gemini / chatGPT: goed in converseren, onbetrouwbaar voor (wiskunde) problemen

AlphaProof concurrent van **openAI o1**

- combineert neurale netwerken **AlphaZero** met symbolische AI in **Lean**
 - wiskundige formalisme voor computers
- kan echt **logisch** redeneren
- zilveren medaille op **Internationale Wiskunde Olympiade 2024**
 - zelfs opgave die maar door 5 van 609 deelnemers kon worden gemaakt
 - maar makkelijkere opgaven juist weer niet!
- wel zelfstandig problemen oplossen
- (nog) niet nieuwe wiskunde bedenken
- veelbelovende ontwikkeling



Google DeepMind en Wiskunde Olympiade 2025

Deed op normale manier mee (dus 4,5 uur per dag) en haalde gouden medaille!

- input en output in **natuurlijke taal**
- kenmerken model (standaard model, geen speciale wiskunde solvers)
 - **Brede Basis-training:** algemeen Gemini-model (Gemini Pro)
 - **Finetuning op Hoogwaardige Data:**
 - aanzienlijke hoeveelheid oplossingen van wiskundecompetities en academische bewijzen
 - **Gespecialiseerde Reinforcement Learning:**
 - sleutel tot de doorbraak
 - niet alleen correct eindantwoord, maar **hele redeneerproces** belonen
 - moedigt model aan om heldere, logisch consistente en stapsgewijze oplossingen te produceren
 - **Verhoogde "Thinking Time" (Test-Time Compute Scaling):**
 - meer tijd en rekenkracht geven om over probleem "na te denken".
 - normaal LLM-antwoord binnen seconden
 - uren aan enkel probleem werken
 - veel mogelijke oplossingspaden verkennen, evalueren en verfijnen
- ook openAI haalde met een vergelijkbaar model een Gouden medaille

AI Agents

Wat zijn AI-agents?

- systeem dat namens iets of iemand taken verricht
- niet alleen vragen beantwoorden
- zelfstandig taken uitvoeren
- plannen kunnen maken en doelen kunnen bereiken

Onderscheid traditionele AI en LLM's

- Planning: breek complex doel af in kleinere, uitvoerbare stappen
- Uitvoering: voer stappen uit
 - gebruik mogelijk verschillende tools (reserveringsystemen, agenda's, etc)
- Evaluatie: controleer of doel is bereikt en pas zo nodig plan aan

AI agents zullen de komende jaren op grote schaal ontwikkeld worden!



AI Agents

Wat kunnen ze al?

- **Geautomatiseerde data-analyse**
 - zelfstandig gegevens verzamelen
 - analyseren en rapport genereren (bv kwartaalomzet)
- **Reisplanning**
 - plan weekendtrip
 - zoek beste vluchten en hotels
 - vergelijk prijzen en beoordelingen
 - boek eventueel direct
- **Webontwikkeling**
 - eenvoudige landingspagina bouwen
 - specifieke functies opnemen
 - genereert volledige code

AI Agents

Toekomst AI-agents

Agents pro-actiever, contextbewuster en interacteren meer met de fysieke wereld.

- **Proactieve persoonlijke assistenten**
 - anticipeert op behoeften (neem paraplu mee op basis weersvoorspelling)
- **Emotioneel-intelligente klantenservice**
 - detecteer emoties van klant via stem of tekst
 - pas respons aan of escaleer naar een menselijke medewerker
- **Robotica-integratie**
 - stuur robots aan in logistieke centra
 - real-time complexe problemen oplossen (defecte robot of onverwachte orderpiek)

AI Agents

Toepassing in **onderwijs**

Individuele **tutor** en adaptieve docent

- onderwijs op maat gesneden
- remedial teaching, etc
- assisteren van docent, niet vervangen
- monitoren voortgang leerling:
 - extra opdrachten en uitleg indien nodig
 - of juist sneller door de stof en moeilijkere opgaven



Algemene Artificiële Intelligentie - AGI



Artificial General Intelligence (AGI)

AI met mogelijkheid te leren, begrijpen en taken uitvoeren op **menselijk** niveau

- **brede cognitieve vaardigheden**: flexibel en onafhankelijk problemen oplossen in verschillende domeinen, zonder specifieke training.
- **leren en redeneren**: leren van ervaring en informatie, logisch redeneren, generaliseren
- **autonomie**: beslissingen nemen en handelen zonder directe instructies
- **bewustzijn** en **zelfreflectie** (mogelijk): geen vereiste voor AGI in technische zin
- **menselijke intelligentie** evenaren of overtreffen: probleemoplossing, communicatie in natuurlijke taal, emotioneel begrip en creativiteit.

Beschouwd als een ultiem doel in AI-wereld

- **technische** en **ethische** uitdagingen

Algemene Artificiële Intelligentie - AGI

Wat moet er nog gebeuren?

- menselijke intelligentie meer dan alleen **denkkracht** hersenen
 - rol zintuigen is belangrijk bij onze ontwikkeling
 - interactie met anderen is heel bepalend: **‘wat maakt de mens?’**
- onze ‘hardware’ past zich nog aan gedurende het leven
 - moet hardware AI systeem ook adaptief zijn?
 - of is één groot systeem als uitgangspunt goed genoeg?
- steeds **nieuwe dingen** leren is essentieel voor menselijke intelligentie
 - AI systemen nu eenmalig getraind en daarna gebruikt
 - on-the-fly verder trainen noodzakelijk?
- **(zelf)bewustzijn** is een nog onbegrepen aspect van menselijke intelligentie
 - moeten we dat expliciet opnemen in AI?
 - of is het een ‘emergent’ verschijnsel en komt dit vanzelf?

De Weg naar AGI – Voorbij de Statische LLM

Van Krachtige Chatbot naar Adaptieve Agent

- **Stand van Zaken**
 - LLM's zijn krachtige, maar statische kennisbases
 - begrijpen de wereld via tekst, maar ervaren hem niet
 - hebben geen geheugen; elke chat is een "nieuw leven"
- **De Fundamentele Beperking**
 - intelligentie meer dan patroonherkenning in tekst
 - echte intelligentie is **belichaamd** (*embodied*), **situated** (in een context), en **actief**
- **De Volgende Stap**
 - LLM voorzien van "**zintuigen**" en een "**geheugen**".
 - van passief instrument naar actieve agent in de wereld.

Bouwsteen 1: Multimodaliteit – De Zintuigen van AI


Zien, Horen en Voelen

- **Recept: De "Modality Bridge"**

- **Encoder:** gespecialiseerd netwerk (bijv. CLIP voor beeld, Whisper voor audio) zet ruwe input om in abstracte vector
- **Projectielaag:** vertaalt vector naar dezelfde "taal" (vectorruimte) als tekst-tokens LLM

- **Resultaat:**

- LLM verwerkt beelden, geluiden en sensordata naadloos samen met tekst
- begrijpt niet alleen *wat* je zegt, maar ook *hoe* (emotie, sarcasme, etc)
- basis voor begrijpen van echte, fysieke wereld



Bouwsteen 2: Extern Geheugen – De toestand van AI

Het Einde van het Eeuwige "Nu"

- **Probleem:**
 - geheugen zit in context: steeds opnieuw aanbieden dezelfde info + extra
 - geen continuïteit en geen gevoel van persistente identiteit
- **Oplossing: Hiërarchisch Geheugensysteem**
 - **Langetermijngeheugen:** externe database van **gecomprimeerde herinneringen** (essentie, niet alle ruwe data!)
 - **Werkgeheugen (Toestand):** actieve, dynamische state die relevante herinneringen voor huidige taak ophaalt en bijhoudt
- **Effect:**
 - AI wordt entiteit met geschiedenis
 - kan leren van eerdere interacties en coherente doelen nastreven over tijd

Visie: AGI als Geïntegreerd Systeem

LLM als 'Brein' van Actieve Agent

- **Hybride Architectuur:**
 - **Laag 1 (Sensoren/Motoren):** gespecialiseerde, snelle netwerken voor waarneming en actie
 - **Laag 2 (Werkgeheugen):** houdt huidige 'toestand' en situatie bij
 - **Laag 3 (LLM Kern):**
 - i. fungeert als denkende 'brein'
 - ii. hoog-niveau redeneren
 - iii. maakt plannen en stelt doelen
 - **Feedback Loop:** Acties veranderen de wereld, nieuwe sensorische input update het model.
- **Van 'Weten' naar 'Zijn':**
 - AI leert niet alleen uit tekst, maar ook door **interactie** met wereld
 - ontwikkelt (**gegrond**) **wereldmodel** gebaseerd op causale relaties
 - i. als ik dit doe, dan gebeurt dat

Conclusie: Bewustzijn als Emergent Verschijnsel?

‘Niet iets speciaals, maar gewoon een emergent verschijnsel van de architectuur’

- **Functionele Visie:**
 - bewustzijn geen magische toevoeging
 - het **emergeert** (verschijnt) wanneer systeem complex, geïntegreerd en staatvol genoeg is.
 - bouwstenen (multimodaliteit, geheugen, zelfmodel) zijn ingrediënten
- **Praktische Weg Vooruit:**
 - niet wachten op theorie van bewustzijn!
 - **bouw architectuur**
 - i. creëer systeem met adaptief, coherent en doelgericht gedrag over langere tijd
 - de vraag ‘Hebben ze écht bewustzijn?’ wordt misschien minder relevant dan observatie dat ze zich er *wel van bewust lijken te zijn*
- **Slotgedachte: De reis van AI naar AGI is een reis van het geven van een lichaam en een geheugen aan een brein**

Dario Amodei's "Machines of Loving Grace"

How AI Could Transform the World for the Better".

Dario Amodei, CEO van Anthropic:

- prominent AI-veiligheidsonderzoeker
- onafhankelijke visie (sloeg aanbod openAI af)
- focus op de risico's van AI
- essay presenteert optimistische visie op toekomst krachtige AI
 - beschrijft hoe AI wereld ten goede kan veranderen
 - hierna samenvatting van essay



Centrale thema's

Potentieel van AI

- potentieel AI wordt onderschat
- AI kan "fundamenteel positieve toekomst" creëren (mits goed ontwikkeld en ingezet)

Noodzaak om risico's te beperken

- essay is (bewust) optimistisch
- benadrukt ook gevaren en noodzaak beperken risico's
- pleit voor verantwoorde ontwikkeling en inzet AI

De "gecomprimeerde 21e eeuw"

- wetenschappelijke en technologische vooruitgang van hele 21e eeuw in 5 - 10 jaar

Biologie en gezondheid

Snelheid ontdekkingen in **biologie** factor **10** sneller, waardoor:

- betrouwbare preventie en behandeling bijna alle infectieziekten
- eliminatie van meeste vormen kanker
- effectieve preventie en genezing genetische ziekten
- preventie Alzheimer
- verbeterde behandeling andere aandoeningen:
 - diabetes, obesitas, hartziekten, auto-immuunziekten
- "Biologische vrijheid"
 - meer controle over gewicht, uiterlijk en voortplanting
- verdubbeling levensduur

AI als "virtuele bioloog": ontwerpen en uitvoeren experimenten door AI

Neurowetenschappen en geest

- genezing meeste psychische aandoeningen:
 - PTSS, depressie, schizofrenie, verslaving
- verbeterde behandeling "structurele" aandoeningen:
 - psychopathie, verstandelijke beperkingen
- effectieve genetische preventie psychische aandoeningen
- oplossingen alledaagse psychologische problemen:
 - woede, concentratieproblemen, angst
- verbetering menselijke basiservaring
 - meer geluk, creativiteit en innerlijke vrede

Verwachting

- inzichten in AI (training) leiden tot revolutie in neurowetenschappen

Economische ontwikkeling en armoede

Rol AI in terugdringen armoede ongelijkheid:

- efficiënte distributie gezondheidsinterventies wereldwijd
- ongekeerde economische groei in ontwikkelingslanden: tot 20% per jaar
- verbetering voedselzekerheid door AI-gedreven landbouwtechnologie
- vermindering van de impact van klimaatverandering.

Erken wel **uitdagingen** van corruptie, zwakke instituten en "opt-out" problematiek (mensen keren zich af AI-technologie)

Vrede en Bestuur

AI op zichzelf geen garantie voor **vrede** en **democratie**:

- kan door democratieën en autoritaire regimes worden ge(mis)bruikt
- samenwerken democratieën behouden voorsprong en vormgeven wereldorde
- pleit voor een "entente strategie":
 - democratieën gebruiken AI-technologie om militaire superioriteit te bereiken
 - voordelen van AI aanbieden aan landen die democratie ondersteunen

Inzet AI kan ook om interne werking democratieën te verbeteren:

- meer onpartijdige rechtspraak en handhaving mensenrechten
- verbeterde besluitvorming en consensusvorming onder burgers
- efficiëntere levering van overheidsdiensten

Werk en Betekenis

- menselijk werk en betekenis zullen niet zullen verdwijnen
- mensen vinden betekenis in relaties, persoonlijke groei en nastreven van doelen
 - zelfs als AI taken beter kan uitvoeren
- economische uitdagingen in wereld waar AI meeste banen kan doen
 - universeel basisinkomen mogelijk, maar er is meer nodig
- nieuwe economische modellen nodig om iedereen te laten profiteren

Conclusie Amodei

Visie op **toekomst** die **radicaal** beter is:

- gedreven door transformerende kracht van AI
- niet vanzelfsprekend
- streven naar verantwoorde en ethische ontwikkeling van AI
- "gecomprimeerde 21e eeuw" biedt enorme kansen
 - vereist ook moed en toewijding
 - focus op menselijke waarden

Citaat

"We hebben de kans om een kleine rol te spelen in het waarmaken van deze toekomst. Hoewel de visie extreem radicaal is, is er ook iets vanzelfsprekends aan. Misschien leiden veel verschillende pogingen om een betere wereld te creëren onvermijdelijk tot ongeveer hetzelfde resultaat." - Dario Amodei

Marc Andreessen - Het Techno-Optimistische Manifest 🚀

Kernboodschap: AI is sleutel tot ongekeende menselijke vooruitgang en welvaart. Angst en regulering zijn grootste obstakels

Visie op AI:

- **Ultiem Gereedschap:** AI krachtig verlengstuk van menselijke intelligentie; een revolutionaire technologie, vergelijk computer, internet of elektriciteit
- **Motor van Vooruitgang:** productiviteit exponentieel verhogen, oplossingen voor grootste problemen van mensheid (ziekte, armoede, energie, etc.)

Grootste Gevaren:

- **Angst & Regulering:** overmatige regulering die innovatie verstikt
- **Niet Snel Genoeg Gaan:** afremmen schadelijker dan risico's

Oplossing:

- **"Accelerate!":** versnellen door vrije marktwerking, open innovatie en concurrentie
- **Innovatie & Markt:** markt en innovatie zorgen vanzelf voor veilige AI-systemen
Vertrouw op vindingrijkheid en ondernemerschap



Thema	Marc Andreessen (De Techno-Optimist) 🚀	Dario Amodi (De Verantwoorde Bouwer) 🛑	Geoffrey Hinton (De Bedachtzame Grondlegger) 🤔
Kernvisie op AI	AI is een gereedschap.	AI is een extreem krachtige technologie die we meer "opkweken" dan bouwen. De controleerbaarheid en voorspelbaarheid ervan zijn wetenschappelijke uitdagingen.	AI is een nieuwe vorm van intelligentie.
De Balans tussen Voordeel en Risico	Focust bijna uitsluitend op de enorme voordelen en ziet het afremmen daarvan als het grootste risico.	Stelt dat mensen zowel de radicale voordelen als de catastrofale risico's onderschatten. De enige manier om de voordelen te behalen, is door de risico's serieus te nemen en proactief aan te pakken.	Focust nu primair op de existentiële risico's, omdat hij gelooft dat deze de voordelen volledig kunnen tenietdoen.
Aanpak & Snelheid	"Accelerate!" De markt en competitie forceren de beste uitkomsten.	"Race to the Top" op het gebied van veiligheid. Hij wil concurreren door veiligere en meer betrouwbare modellen te bouwen, en hoopt dat anderen dit voorbeeld volgen.	Pauzeren of vertragen. De snelheid is op dit moment het probleem.
Rol van Regulering	Regulering is schadelijk voor innovatie.	Regulering is noodzakelijk, maar moet weloverwogen zijn. Hij pleit voor duidelijke veiligheidsstandaarden, transparantie en internationale overeenkomsten om misbruik te voorkomen.	Strikte, mogelijk wereldwijde, controle is essentieel, vergelijkbaar met nucleaire verdragen.

Laatste ontwikkelingen


AI Race

Grote techbedrijven maken steeds grotere AI modellen met meer mogelijkheden

- alleen zij kunnen dit momenteel betalen
- de VS investeert zwaar in AI: willen monopolie positie

Goedkopere AI

- met minder rekenkracht proberen hetzelfde te bereiken
- **DeepSeek** lijkt een eerste geslaagde poging in die richting
 - voor minder dan 1/10 van de kosten
 - met vergelijkbare prestaties
 - maakt gebruik van '**knowledge distillation**': slim leren van bestaand model
 - heeft architectuur die sneller trainbaar is
- hopelijk keerpunt!



Conclusie en Toekomst

- betrekkelijk **vroeg** in ontwikkeling van AI
- er gebeurt op dit moment van alles!
- taalmodellen hebben alles op zijn kop gezet
- maar zijn extreem **duur** om te maken
- en zijn ze de weg naar **AGI**?
- blijven de grote techbedrijven de markt beheersen en hoe gevaarlijk is dat?
- wat gaat er in **Europa** gebeuren, we lijken nu de boot te missen
- wat zullen de maatschappelijk gevolgen zijn van het gebruik van AI?
- op welke termijn zal **AGI** doorbreken en wat zullen de gevolgen zijn?
- zullen er op korte termijn goedkopere goed werkende modellen komen?
- goede regulering is een absolute must!

